Sprachkonzepte

Teil 2: Sprachen

Syntax, Semantik, Pragmatik

Sprachen

Sprache = System von Zeichen, das der Gewinnung und Ausprägung von Gedanken, ihrem Austausch zwischen verschiedenen Menschen sowie der Fixierung von erworbenem Wissen dient *(Meyers Großes Standardlexikon, 1983)*

- in der Informatik geht es um die Fixierung von Gedanken zu Daten und Algorithmen in einer Form, die auf Rechnern nutzbar ist
- natürliche Sprachen gibt es etwa 6500
  (https://de.wikipedia.org/wiki/Sprachfamilien_der_Welt)
- Programmiersprachen gibt es auch mindestens einige hundert,
  je nachdem wie eng man den Begriff der Programmiersprache fasst

Programmiersprachen

Programmiersprachen sind formale Sprachen, die der Implementierung von Datenstrukturen und Algorithmen auf Rechner dienen

Der Programmierbegriff ist hier bewusst etwas weiter als üblich gefasst.
Meist wird nur das Implementieren von Algorithmen als Programmieren aufgefasst.
Sprachen wie etwa SQL, XML, HTML, CSS sind dann keine Programmiersprachen.

Aspekte einer Programmiersprache:

- **Syntax**

  Welche Symbole gibt es? — Vokabular
  Wie dürfen die Symbole kombiniert werden? — Grammatik

- **Semantik**

  Welche Symbolfolgen haben Bedeutung? — statische Semantik
  Und welche Bedeutung ist das? — dynamische Semantik

- **Pragmatik**

  Für welche Zwecke ist die Sprache geeignet? — Domänen
  Wie drückt man sich in der Sprache am besten aus? — Stil

1) *Syntax*

2) *Semantik*

3) *Pragmatik*

Syntax: Vokabular

Übliches Vokabular von Programmiersprachen:

- Kommentare *ohne Einfluss auf die Bedeutung des Programms*
- Zwischenraum *(whitespace)*
- Terminalsymbole *(tokens)*

Schlüsselwörter *(keywords)*	*if, else, while, ...*
Trennzeichen *(seperators)*	*Klammern, Punkt, Komma, Semikolon, ...*
Operatoren	***+, -, *, /, ...***
Literale	*Zahlen, Strings, ...*
Bezeichner *(identifiers)*	*Variablennamen, ...*

Vokabulare werden mit regulären Ausdrücken formal spezifiziert.

die regulären Ausdrücke beschreiben die Zusammenfassung von Einzelzeichen zu Elementen des Vokabulars

Vokabular: Reguläre Ausdrücke (1)

Prinzipieller Aufbau von **regulären Ausdrücken**:

- Zeichenklassen sind elementare reguläre Ausdrücke:

`a`	*das Zeichen `'a'`*
`[abc-e]`	*eines der Zeichen `'a'`, `'b'`, `'c'`, `'d'` oder `'e'`*
`[^abc-e]`	*keines der Zeichen `'a'`, `'b'`, `'c'`, `'d'` oder `'e'`*
`.`	*beliebiges Zeichen (außer Zeilenwechsel)*

- Quantifizierung eines beliebigen regulären Ausdrucks **`r`**:

`r{2}`	*zweimal hintereinander*
`r{1,3}`	*ein bis drei Wiederholungen*
`r?`	*entspricht `r{0,1}`*
`r*`	*entspricht `r{0,}`, d.h. beliebig oft inklusive keinmal*
`r+`	*entspricht `r{1,}`, d.h. mindestens einmal*

- Verknüpfung beliebiger regulärer Ausdrücke **`r`** und **`s`**:

`rs`	*Konkatenation, d.h. erst `r`, dann `s`*
`r|s`	*Alternative, d.h. `r` oder `s`*
`(r)`	*Klammerung zum Überschreiben der Vorrangregeln (Quantifizierung vor Konkatenation vor Alternative)*

Vokabular: Reguläre Ausdrücke (2)

Viele Implementierungen von regulären Ausdrücken enthalten Erweiterungen, z.B java.util.regex:

- vordefinierte Zeichenklassen

  \d *steht für* ***[0-9]***
  \D *steht für* ***[^0-9]***
  ...

- unterschiedlich aggressive Einstellung der Quantifizierungen

  greedy ***.*foo*** *findet in* ***fooxxxfoo*** *einzig den Token* ***fooxxxfoo***
  .* *verbraucht zunächst die gesamte Eingabe, aber in einem anschließenden Backtracking wird geprüft, ob die letzten verbrauchten Zeichen* ***foo*** *waren*

  possessive ***.*+foo*** *findet in* ***fooxxxfoo*** *keinen Token*
  wie greedy, nur ohne Backtracking

  reluctant ***.*?foo*** *findet in* ***fooxxxfoo*** *zwei Tokens* ***foo*** *und* ***xxxfoo***
  .*? *verbraucht zunächst kein Zeichen der Eingabe, der Verbrauch wird dann schrittweise erhöht, um eventuell* ***foo*** *zu matchen*

Reguläre Ausdrücke: Beispiel (1)

Lexikalische Analyse arithmetischer Ausdrücke mit dem Compilerbau-Werkzeug ANTLR4 von Terence Parr:

```
// ExprLexer.g4
lexer grammar ExprLexer;

Number: Digits ('.' Digits)? ;
fragment Digits: ([0-9])+ ;

PLUS:  '+';
MINUS: '-';
MUL:   '*';
DIV:   '/';
LPAREN: '(';
RPAREN: ')';

WS: [ \t\r\n]+ -> channel(HIDDEN);
```

regulärer Ausdruck für den Token Number (Tokennamen beginnen mit Großbuchstaben)

Digits ist kein Token, sondern benennt nur einen Hilfsausdruck

Zwischenraum (whitespace) soll nicht in die Ergebnis-Tokenfolge aufgenommen werden

Reguläre Ausdrücke: Beispiel (2)

Aus der Datei **`ExprLexer.g4`** generiert ANTLR4 eine Klasse **`ExprLexer.java`**. Die Klasse enthält einen Automaten, der die Tokens gemäß den regulären Ausdrücken erkennt.

Die erstellte Tokenfolge kann anschließend mit einer in EBNF geschriebenen Grammatik auf eine syntaktische korrekte Reihenfolge geprüft werden.

- Beispiel:

  Aus einer eingelesenen Zeichenfolge

  ```
  1.2 + 34.5
  ```

  wird in der lexikalischen Analyse eine Tokenfolge

  ```
  Number("1.2") PLUS("+") Number("34.5")
  ```

  bzw. mit dem verborgenen Whitespace

  ```
  Number("1.2") WS(" ") PLUS("+") WS(" ") Number("34.5")
  ```

Syntax: Grammatik

Grammatikregeln (Produktionen) legen die erlaubten Tokenfolgen fest.

- bei den üblicherweise verwendeten kontextfreien Grammatiken haben Produktionen die Form

  Nichtterminalsymbol **=** *Folge von Terminal- und Nichtterminalsymbolen*

- eines der Nichtterminalsymbole wird als Startsymbol ausgezeichnet

  aus dem Startsymbol lassen sich durch wiederholte Anwendung von Produktionen alle syntaktisch gültigen Tokenfolgen (= Folgen von Terminalen) ableiten

Grammatiken werden mit EBNF *(extended Backus-Naur form)* formal spezifiziert.

Grammatik: EBNF

Aufbau von **EBNF (Erweiterte Backus-Naur-Form)**:

- Terminale sind nicht weiter ersetzbar elementare Symbole (= Tokens)

  `"abc"` *Zeichenfolge abc*

- Nichtterminale sind per Produktionsregel ersetzbare elementare Symbole

  `name` *frei wählbarer Bezeichner*

- Symbolfolgen aus Symbolfolgen s und t mit Terminalen und Nichtterminalen

  `st` *s gefolgt von t*
  `s|t` *entweder s oder t*
  `{s}` *beliebig viele s inklusive keinmal*
  `[s]` *kein oder ein s*

  } *Erweiterung gegenüber BNF*

  `(s)` *Klammerung zum Überschreiben der Vorrangregeln*

- Produktionsregeln:

  ```
  Nichtterminal = Symbolfolge ;
  ```

EBNF: Beispiel (1)

Syntaxanalyse arithmetischer Ausdrücke mit ANTLR4:

```
// ExprParser.g4
parser grammar ExprParser;
options { tokenVocab=ExprLexer; }

expr : multExpr
     | expr (PLUS | MINUS) multExpr
     ;

multExpr : primary
         | multExpr (MUL | DIV) primary
         ;

primary : LPAREN expr RPAREN
        | value
        ;

value : (PLUS | MINUS)? Number
      ;
```

EBNF: Beispiel (2)

Aus **`ExprParser.g4`** generiert ANTLR4 eine Klasse **`ExprParser.java`**.
Die Klasse enthält Methoden, die eine eingelesene Tokenfolge auf syntaktisch korrekte Reihenfolge prüfen.

ANLR4 erstellt aus der Tokenfolge einen Syntaxbaum (parse tree).

- Beispiel:

  Syntaxbaum zum Ausdruck

  `1.2 + 34.5`

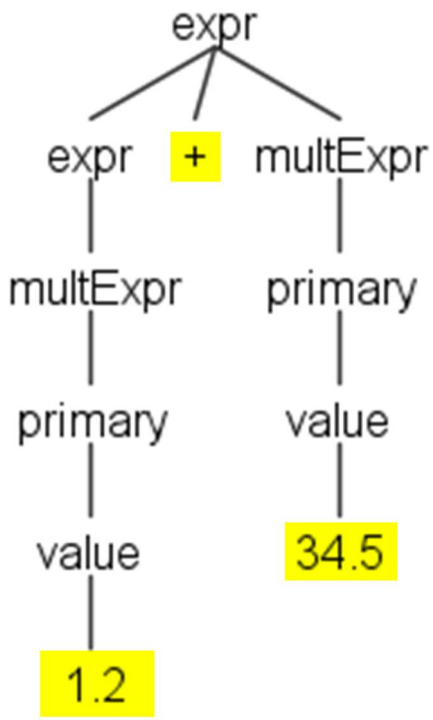

Abstrakte Syntax (1)

Die **abstrakte Syntax** einer Sprache beschreibt, *was* man mit der Sprache ausdrücken kann, und abstrahiert davon, *wie* man es ausdrückt.

- Beschreibung mit einem Modell, das die Elemente der Sprache mit ihren Beziehungen zeigt
- Beispiel:

  Modell für arithmetische Ausdrücke mit Elementen **Value** und **Operation**

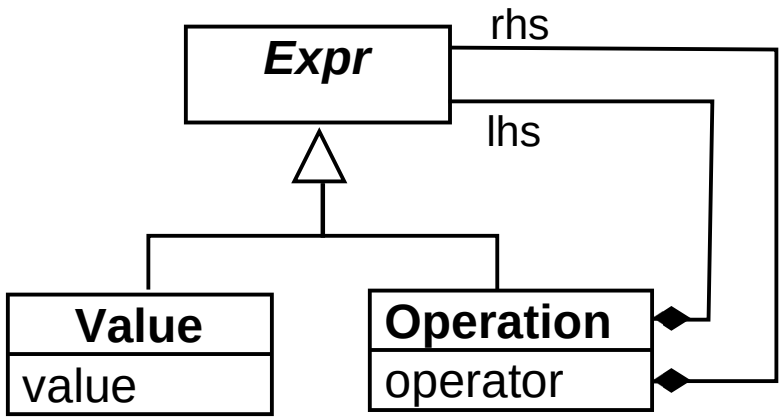

Abstrakte Syntax (2)

Ein **AST** *(Abstract Syntax Tree)* zeigt eine Formulierung als Instanz des Modells der Sprache.

- Beispiel:

  Abstrakter Syntaxbaum (**AST**) des Ausdrucks `1.2 + 34.5`

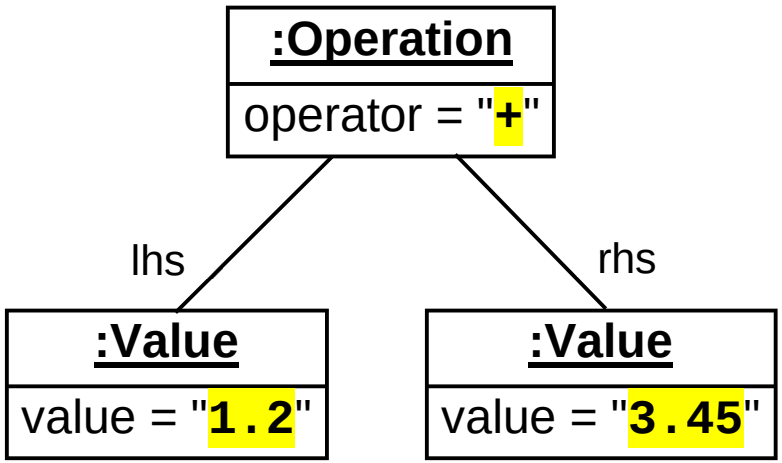

der AST wird aus dem Syntaxbaum (parse tree) der konkreten Syntax abgeleitet

1) *Syntax*

2) *Semantik*

3) *Pragmatik*

Semantik (1)

Nicht jede syntaktisch korrekte Symbolfolge ist auch semantisch korrekt

- Beispiel für semantischen Unsinn in syntaktisch korrektem Deutsch:

> Dunkel war’s, der Mond schien helle,
> schneebedeckt die grüne Flur,
> als ein Wagen blitzesschnelle,
> langsam um die Ecke fuhr.
>
> Drinnen saßen stehend Leute,
> schweigend ins Gespräch vertieft,
> als ein totgeschoss’ner Hase
> auf der Sandbank Schlittschuh lief.
>
> ...

Quelle: https://de.wikipedia.org/wiki/Dunkel_war's,_der_Mond_schien_helle

Semantik (2)

- Beispiel für semantischen Unsinn in syntaktisch korrektem Java:

```
public abstract final class Beispiel {
    public private static void main(String[] args) {
        System.out.print(123456789012345678 90);
        System.out.print(x);
    }
}
```

das obige Programm enthält vier semantische Fehler

Statische Semantik (1)

Die **statische Semantik** einer Programmiersprache regelt die Wohlgeformtheit von Formulierungen in Form von Konsistenzregeln für den AST.

- einfache Konsistenzregeln lassen sich unter Umständen mit einer strikten konkreten Syntax erzwingen

  allerdings kann eine strikte Grammatik sehr umfangreich werden und eventuell unflexibel hinsichtlich späterer Spracherweiterungen sein

- Konsistenzregeln für komplexe Beziehungen zwischen Sprachelementen können in der Regel erst nach der Syntaxanalyse auf dem AST geprüft werden

  klassische Beispiele sind die Regeln zur Eindeutigkeit von Namen und Regeln zur Typsicherheit von Ausdrücken: Typdeklarationen und Verwendungen von Namen können im Text sehr weit verstreut stehen

Statische Semantik (2)

- Beispiele für semantische Fehler in Java:

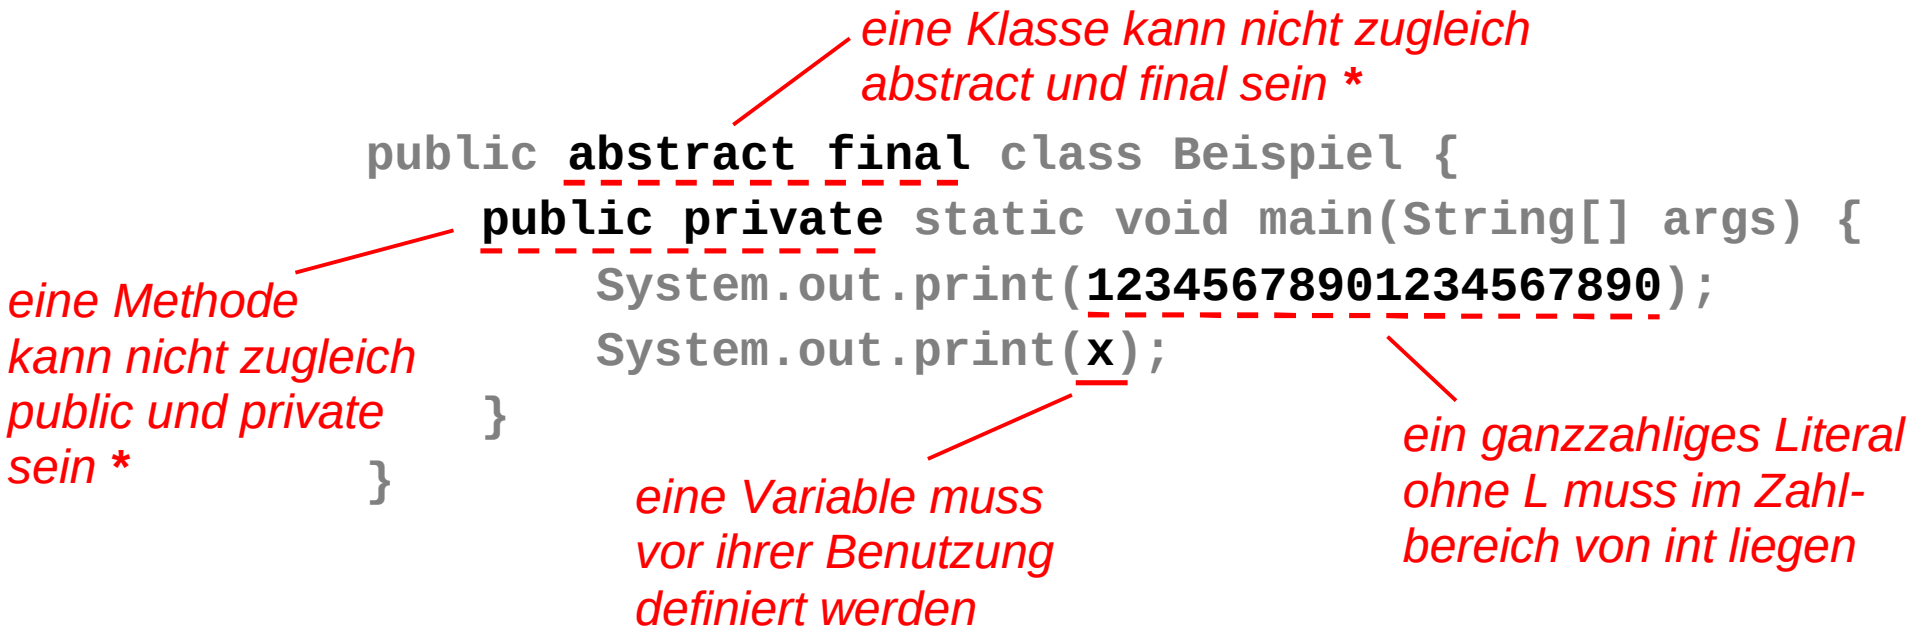

** die Kombinationen **abstract final** und **public private** könnte man alternativ auch mit einer strikten konkreten Syntax verhindern*

Dynamische Semantik

Eine **dynamische Semantik** beschreibt, was das mit der Programmiersprache Formulierte bewirkt.

Für einen AST kann man im Prinzip mehrere dynamische Semantiken festlegen:

- etwa eine Semantik in Form eines Interpreters, der den AST ausführt

  z.B. den AST eines arithmetischen Ausdrucks in Tiefensuche ablaufen und dabei den Wert des Ausdrucks berechnen

- oder eine Semantik in Form eines Compilers, der aus dem AST eine Befehlsfolge für einen Prozessor generiert

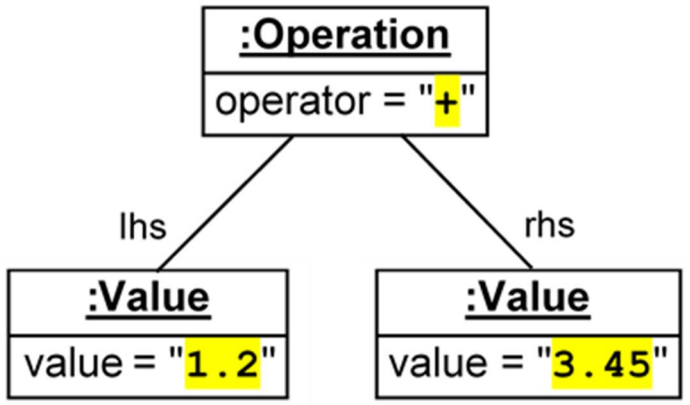


```
# Befehle für den desk calculator dc unter Linux
6       # 6 auf den Stack
k       # Genauigkeit 6 Nachkommstellen
1.2     # 1.2 auf den Stack
34.5    # 34.5 auf den Stack
+       # Summe auf den Stack
p       # Ergebnis ausgeben
```

1) *Syntax*

2) *Semantik*

3) *Pragmatik*

Pragmatik: Domänen (1)

Eine **Domäne** ist in der Softwartetechnik ein abgrenzbares Problemfeld oder ein bestimmter Einsatzbereich für eine Software *(siehe Wikipedia "Problemdomäne")*

Einteilung von Programmiersprachen nach ihrem Domänenbezug:

- **GPL** *(General-purpose Language)*

  GPLs haben eine universelle Syntax und Semantik, die sie für viele verschiedene Domänen einsetzbar macht

  der Domänenbezug entsteht durch domänenspezifische Bibliotheken und Frameworks, die in der Sprache implementiert sind

  alle höheren Programmiersprachen werden hier üblicherweise eingeordnet, z.B. Java, C, C++, Python, Scala, ...

- **DSL** *(Domain-specific Language)*

  DSLs sind in Syntax und Semantik auf eine spezifische Domäne abgestimmt

  z.B. SQL für die Domäne Datenbanken
  z.B. HTML und CSS für die Domäne Webseiten

Pragmatik: Domänen (2)

Der Übergang zwischen GPLs und DSLs ist fließend:

- auch eine GPL kann für bestimmte Domänen besser und für andere schlechter oder gar nicht geeignet sein

  C und C++ eignen sich z.B. besonders gut für die Domäne Systemprogrammierung, unter anderem, weil sie den Typ Adresse unterstützen

  in manchen Domänen sind funktionale Spracheigenschaften besonders nützlich, in anderen objektorientierte, usw.

  häufig fällt die Entscheidung für eine GPL aber wegen der verfügbaren Bibliotheken und Frameworks, weniger wegen der bei vielen GPLs ähnlichen Spracheigenschaften

- manche APIs von GPL-Bibliotheken lassen sich fast wie eine DSL verwenden

  die Namen der Bibliotheksfunktionen bilden das Vokabular und die möglichen Aufrufreihenfolgen und Aufrufverschachtelungen der Funktionen die Syntax

  man nennt solche APIs Fluent Interfaces oder interne DSLs

Pragmatik: Stil (1)

Bei **Stil** geht es um diejenigen Merkmale eines Textes, die nicht die Bedeutung betreffen, sondern nur die Art und Weise, wie diese Bedeutung sprachlich formuliert ist. *(sinngemäß aus Wikipedia "Stil", Abschnitt "Sprache")*

beim Programmieren lässt sich auch mit ein und derselben Sprache die gleiche Bedeutung meist auf unterschiedliche Art und Weise erzielen, also mit unterschiedlichem Stil

Stilaspekte bei Programmiersprachen:

- Programmorganisation
  Aufteilung in Dateien und Ordner, Gliederung, ...
- Layout
  Einrückung, Whitespace, Zeilenlänge, ...
- Namenskonventionen
  Zeichenvorrat, Groß- / Kleinschreibung, Aufbau, Länge, ...
- Idiome *(Redewendungen)*
  übliche Formulierungen für wiederkehrende Situationen, bevorzugte und geächtete Sprachelemente, ...

Pragmatik: Stil (2)

Für GPLs gibt es oft viele, mitunter auch konkurrierende Stilempfehlungen.

Anspruch der Empfehlungen ist immer, dass sie die Codequalität verbessern, etwa hinsichtlich Lesbarkeit, Wartbarkeit und Fehlerrisiken. Ob sie diesen Anspruch einlösen, ist teilweise umstritten

Beispiele für Stilempfehlungen zur Sprache C:

- MISRA C *(Motor Industry Software Reliability Association)*
- SEI CERT C Coding Standard
- Linux kernel coding style
- GNU coding standards